

Projet d'Analyse de Données : Performance en Salle de Sport

Timeo Bossuet, Charles Ganne

Table des matières

1	Introduction : chargement et découverte du jeu de données	1
2	Analyse unidimensionnelle	2
2.1	Variables quantitatives	2
2.2	Variables qualitatives	7
3	Analyse bidimensionnelle	7
3.1	Corrélations entre variables quantitatives (Figure 7)	7
3.2	Variables quantitatives en fonction de variables qualitatives	9
4	Analyse en composantes principales	12
4.1	Analyse de l'ACP	13
5	Classification non supervisée (Clustering)	14
5.1	Classification Ascendante Hiérarchique (CAH)	15
5.2	Méthode des K-means	16
5.3	Comparaison des classifications	16
5.4	Croisement et Profilage	18
6	Conclusion	19

1 Introduction : chargement et découverte du jeu de données

Ce projet a pour objectif de mener l'étude descriptive uni- et bi-dimensionnelle d'un jeu de données concernant les clients d'une salle de sport. Voici les 6 premières lignes du jeu de données pour s'en faire une première idée.

	gender	weight	height	duration	calories	fat	water	level	bmi
1	Male	88.3	1.71	1.69	1313	12.6	3.5	3	30.20
2	Female	74.9	1.53	1.30	883	33.9	2.1	2	32.00
3	Female	68.1	1.66	1.11	677	33.4	2.3	2	24.71
4	Male	53.2	1.70	0.59	532	28.8	2.1	1	18.41

5	Male	46.1	1.79	0.64	556	29.2	2.8	1	14.39
6	Female	58.0	1.68	1.59	1116	15.5	2.7	3	20.55

Ce jeu de données comprend des mesures empiriques réalisées sur un échantillon de 973 usagers. Chaque personne est décrite par les variables suivantes :

- *gender* : Sexe du membre de la salle de sport (homme ou femme)
- *weight* : Poids du membre en kilogrammes
- *height* : Taille du membre en mètres
- *duration* : Durée de chaque séance d'entraînement en heures
- *calories* : Total des calories brûlées au cours de chaque séance
- *fat* : Pourcentage de graisse corporelle du membre (appelé "masse grasse")
- *water* : Consommation quotidienne d'eau pendant les séances d'entraînement
- *level* : Niveau d'expérience : débutant (1), intermédiaire (2) et expert (3)
- *bmi* : Indice de masse corporelle (IMC), calculé à partir de la taille et du poids

On observe que la variable *gender* est qualitative nominale et la variable *level* est qualitative ordinaire. De plus, la variable *calories* est quantitative discrète. Les autres variables sont quantitatives continues. Il faut préciser à R les variables qui doivent être considérées comme qualitatives. On utilise donc la fonction `as.factor()` sur les variables *gender* et *level* :

```
SalleDeSport$gender <- factor(SalleDeSport$gender,
                              levels=c("Male","Female"),
                              labels = c("Homme", "Femme"))
SalleDeSport$level <- factor(SalleDeSport$level, levels=c("1","2","3"),
                              labels=c("Débutant","Intermédiaire","Expert"),
                              ordered=TRUE)
```

2 Analyse unidimensionnelle

On commence par étudier chaque variable individuellement.

2.1 Variables quantitatives

Pour chaque variable quantitative, on examine des statistiques descriptives (moyenne, médiane, quartiles, etc.). On trace chaque boxplot, et certains histogramme.




Figure 1: Boxplots : poids, masse grasse, IMC et calories

2.1.1 Poids (weight)

Le boxplot (Figure 1) montre une médiane de 70 kg, avec une dispersion notable (la moitié des individus se situe entre 58 et 86 kg). On observe des valeurs atypiques élevées (points au-dessus de 125–130 kg). L’histogramme a confirmé une distribution asymétrique à droite : beaucoup d’individus entre 50 et 85 kg avec un maximum de fréquence autour de 60–70 kg. On a observé une queue à droite marquée, correspondant à des individus plus lourds (au-delà de 100 kg), déjà visibles comme valeurs atypiques/outliers sur le boxplot. La distribution n’est donc pas strictement gaussienne.

2.1.2 Masse grasse (fat)

La médiane est autour de 26%, avec la majorité des valeurs entre 21% et 29%. L’étendue va approximativement de 10% à 35%. Le boxplot (Figure 1) ne montre pas de points atypiques extrêmes ; l’ensemble semble relativement homogène, avec une dispersion modérée. L’histogramme (Figure 2) semble légèrement multimodal, ce qui peut refléter des différences physiologiques (genres ou niveaux).

2.1.3 IMC (bmi)

On observe une médiane de 24, avec la moitié des individus entre 20 et 28. En revanche, on observe de nombreux outliers élevés (au-delà de 40 et jusqu’à 50). Cette queue droite importante sur l’histogramme (Figure 2) confirme la présence d’individus en surpoids ou obésité, déjà visible sur le boxplot via de nombreux outliers. Cela rejoint nos observations sur le poids où on avait remarqué déjà la présence d’outlier avec des individus bien au delà de 100kg.




Figure 2: Histogrammes : masse grasse et IMC

2.1.4 Calories (calories)

Le boxplot (Figure 1) indique une médiane proche de 900 kcal, avec un intervalle interquartile d'environ 750 à 1100 kcal. On voit plusieurs valeurs atypiques élevées (au-delà de 1600/1750 kcal), ce qui indique des séances exceptionnellement énergivores. Cette structure est cohérente avec une distribution asymétrique à droite : des séances “standard”, et quelques séances très intenses (Figure 3). Les 30 bins sont adaptés ici, ils révèlent la forme globale, tout en conservant la visibilité de la queue à droite. Un nombre plus faible masquerait les extrêmes.




Figure 3: Histogrammes : calories et consommation d'eau




Figure 4: Boxplots : eau, durée et taille

2.1.5 Eau (water)

Figure 4, la médiane est autour de 2,6 L, et l'intervalle interquartile va de 2,2 à 3,1 L. L'étendue est d'environ 1,5 à 3,7 L. La distribution paraît assez concentrée autour de 2–3 L, sans valeurs extrêmes marquées. Figure 3, on remarque des pics marqués autour de certaines valeurs (notamment 2,7

L et 3,5 L), suggérant des valeurs arrondies ou/et des comportements standardisés (bouteilles, recommandation de cette salle de sport).

2.1.6 Durée (duration)

Figure 4, la médiane est autour de 1,25 h, et la moitié des séances se situe approximativement entre 1,05 et 1,45h. Les durées extrêmes vont d'environ 0,5 h à 2 h. L'histogramme (Figure 5) montre une concentration nette entre 1 h et 1,5 h, avec quelques séances plus courtes et plus longues. Ça pourrait par exemple être une recommandation de la salle de sport de faire une séance courte, deux séances moyennes et une séance longue par semaine. Les 30 bins permettent de bien visualiser le pic entre 1h et 1,5 h sans trop lisser.

2.1.7 Taille (height)

Figure 4, la médiane est proche de 1,70–1,72 m, avec un intervalle interquartile entre 1,62 et 1,80 m. Le boxplot ne met pas en évidence d'outliers. L'histogramme (Figure 5) suggère une distribution plutôt concentrée entre 1,60 et 1,80 m, avec deux petites “bosses” (distribution pas parfaitement en cloche, probablement liée au fait que hommes et femmes soient dans le même jeu de données), mais sans valeurs extrêmes dominantes. En traçant les graphiques avec différents nombres de bins, on a remarqué que certaines configurations masquaient le double pic tandis que d'autres le faisait clairement apparaître. On a donc choisi 19 bins pour qu'ils apparaissent sans trop montrer les petites variations autour.




Figure 5: Histogrammes : durée des séances et taille des adhérents

2.2 Variables qualitatives

Étudions à présent les distributions des variables qualitatives `gender` et `level`. On visualise ces répartitions avec des diagrammes en barres.




Figure 6: Répartition des adhérents par genre et par niveau

2.2.1 Le genre

Le diagramme en barres (Figure 6) montre une répartition relativement équilibrée entre hommes et femmes, avec une légère majorité d'hommes dans l'échantillon. Cette distribution suggère une population globalement mixte, ce qui limite le risque de biais lié à une surreprésentation marquée d'un genre.

2.2.2 Le niveau

La répartition par niveau d'expérience met en évidence une majorité d'individus de niveau intermédiaire et de débutants. Les experts constituent le groupe le moins représenté. Cette structure est cohérente avec un contexte de pratique sportive, où les niveaux intermédiaires sont généralement les plus fréquents, tandis que les niveaux experts restent plus rares.

3 Analyse bidimensionnelle

3.1 Corrélations entre variables quantitatives (Figure 7)

On explore à présent les relations entre les variables quantitatives avec des matrices de corrélations.




Figure 7: Matrices de corrélations, séparées par genres

Sur la matrice mixte, on a observé une corrélation positive entre le poids et la taille, les individus plus grands auraient tendance à être plus lourds. L'IMC, défini à partir du poids et de la taille, est logiquement très fortement corrélé au poids. En revanche, sa corrélation avec la taille apparaît faible et légèrement négative dans l'échantillon global. Lorsque l'analyse est menée séparément chez les hommes et les femmes, cette corrélation négative devient plus marquée, ce qui est plus cohérent avec la formule de calcul de l'IMC et suggère que l'effet de la taille est en partie masqué dans l'analyse globale. De plus, la corrélation entre poids et taille disparaît complètement lorsqu'on sépare hommes et femmes.

La relation entre la durée des séances et les calories brûlées est particulièrement forte, ce qui confirme que la dépense énergétique dépend avant tout du temps consacré à l'effort. La consommation d'eau est également positivement liée à la durée et aux calories, bien que de manière plus modérée. Ces relations restent globalement stables lorsque l'on distingue les hommes et les femmes, ce qui indique des mécanismes communs indépendants du genre.

La masse grasse se distingue par des corrélations négatives avec la durée des séances, les calories brûlées et la consommation d'eau. Cela suggère que les individus présentant un pourcentage de masse grasse plus élevé ont tendance à réaliser des séances plus courtes et moins intenses, accompagnées d'une hydratation plus faible. À l'inverse, les variables morphologiques telles que le poids et la taille ne sont pas liées aux indicateurs de performance sportive considérés ici. Cette dissociation indique que, dans ce jeu de données et avec ces variables, la morphologie seule n'explique pas directement les performances, qui semblent davantage dépendre de l'effort fourni et de la composition corporelle.

Enfin, il est étonnant de voir que le masse grasse n'est pas corrélé au poids ou à l'IMC. Cette variable n'augmente donc pas mécaniquement avec le poids, surtout dans une population sportive où la masse musculaire peut représenter une part importante du poids total. Cette observation avait déjà été faite lors de l'expérience super-size me. Le sujet n'avait pas prit beaucoup de poids

mais était quand même devenu en très mauvaise santé, notamment à cause de sa masse grasse (et beaucoup d'autres troubles liés à la junk-food).

3.2 Variables quantitatives en fonction de variables qualitatives

Comparons les distributions des variables quantitatives selon le genre et le niveau à l'aide de box-plots.




Figure 8: Calcul du rapport de corrélation eta2

Sur la Figure 8, pour chaque variable quantitative, on calcule le rapport de corrélation η^2 vis-à-vis de chaque variable qualitative (genre et niveau) à l'aide de la fonction `eta2()`. Les valeurs obtenues donnent, pour chaque variable quantitative, la part de variance expliquée par le genre ou par le niveau. Par exemple, la valeur élevée de η^2 entre duration et level suggère que la durée moyenne de séance varie selon l'expérience. Des valeurs proches de 0 (entre height et level, par exemple) signifient une absence de lien fort.




Figure 9: Boxplots des variables quantitatives selon le genre

Séparation par genre (Figure 9) : On observe une différence de poids notable entre les hommes et les femmes, en lien avec une différence de taille. La corrélation poids-taille est faible lorsqu'on sépare par sexe, mais restait modérée sur la matrice mixte (0.37). La durée des séances et les calories dépensées ne sont pas liées au sexe (η^2 proche de 0), bien que des outliers soient présents pour la variable calories chez les deux genres. La masse grasse est globalement plus élevée chez les femmes, qui consomment également moins d'eau. Toutefois, la corrélation négative entre consommation d'eau et masse grasse persiste lorsqu'on sépare par sexe, indiquant que ce lien est indépendant du genre. Enfin, des cas d'IMC très élevés apparaissent uniquement chez les hommes, mais uniquement sous forme d'outliers. Les individus présentant un IMC très élevé apparaissent uniquement sous forme d'outliers et ne sont pas représentatifs de la population étudiée, ce qui empêche toute généralisation.




Figure 10: Boxplots des variables quantitatives selon le niveau

Séparation par niveau (Figure 10) : Le poids ne semble pas directement lié au niveau, les trois groupes présentant des intervalles inter-quartiles similaires et une valeur de η^2 proche de zéro. Toutefois, les experts se distinguent par une dispersion plus faible. La durée des séances quand à elle est fortement associée au niveau, avec une augmentation nette de la durée à mesure des niveaux d'expertise, ce que confirme une valeur élevée de η^2 . Cette relation se retrouve logiquement pour les calories dépensées, compte tenu de leur forte corrélation avec la durée. La consommation d'eau suit également cette tendance, mais de façon moins marquée, ce qui s'explique principalement par l'intensité et la durée des séances plutôt que par un effet direct du niveau. La masse grasse apparaît comme un facteur très discriminant du niveau, les experts présentant systématiquement des valeurs plus faibles et une distribution plus resserrée que les débutants et intermédiaires. L'analyse de l'IMC et du poids confirme cette observation : les experts ont des valeurs concentrées dans une plage étroite, tandis que les débutants et intermédiaires présentent une dispersion plus large, incluant des situations de maigreur et d'obésité, les cas d'obésité sévère apparaissant uniquement sous forme d'outliers.

En conclusion, l'expertise se distingue par une masse grasse réduite (12-18 %). Bien que le genre influence la répartition des masses grasses et les extrêmes de l'IMC, la performance reste dictée par la durée des séances et l'intensité de la dépense calorique. Ces résultats confirment que l'assiduité à l'entraînement est le principal levier pour optimiser sa santé physique.

4 Analyse en composantes principales

Le principe de l'ACP repose sur la création de composantes principales par combinaison linéaire des variables originales. En éliminant la redondance d'information (corrélations), cette méthode permet de visualiser les individus sur des plans factoriels et d'identifier les axes qui expliquent la plus grande part de l'inertie du nuage de points.

Le jeu de données oppose ici la **morphologie** (poids, taille, IMC, masse grasse) à la **pratique sportive** (durée, calories, eau, niveau).

L'analyse préalable montre de fortes corrélations, notamment entre la durée et les calories, ou le poids et l'IMC. En raison de l'hétérogénéité des unités (kg, h, kcal), nous avons vu qu'elles n'étaient pas à la même échelle. Nous appliquons donc une **ACP centrée réduite**. Cette normalisation assure une contribution équitable de chaque variable à l'inertie, empêchant les variables à forte variance (comme les calories) de dominer l'analyse.




Figure 11: Inertie expliquée par les composantes principales de l'ACP

Les deux premiers axes factoriels (Figure 11) expliquent 68,3% de l'inertie totale (41,5% pour l'axe 1 et 26,8% pour l'axe 2), assurant une représentation fidèle des données. Bien que l'essentiel de l'analyse repose sur ce premier plan factoriel, la contribution du troisième axe (17,6%) reste significative et ne sera pas totalement oubliée lors de l'interprétation.

4.1 Analyse de l'ACP




Figure 12: Cercle des corrélations sur le plan factoriels 1-2

Dans un premier temps, on remarque que les flèches des variables poids, durée, calories, eau, IMC sont plus longues. Ces variables sont donc bien représentées sur le plan factoriel 1-2 (Figure 12). La flèche de la hauteur est plus proche du centre, cette variable est donc moins bien représentée par les deux premières composantes principales.




Figure 13: Matrice des corrélations entre les variables et les axes 1, 2 et 3 de l'ACP

L'axe des abscisse (Dim1, 41.5 %) est corrélé plus fortement à calories (0.80), durée (0.73), eau (0.73) et masse grasse (-0.83) (Figure 13). Ainsi, cette composante principale rassemble les variables durée, calories et eau, qui traduisent de l'intensité d'un entraînement, et les oppose à la variable masse grasse. C'est une observation que nous avons faite précédemment, les personnes avec une masse grasse plus élevées font des séances moins intenses.

L'axe des ordonnées est principalement corrélé à l'IMC et au poids, les deux flèches sont très proches. Il est également négativement corrélé à la durée et aux calories. Cela nous permet d'opposer la corpulence des individus et leur endurance.




Figure 14: Cercles des corrélations sur le plan factoriel 1-3

Enfin, la troisième composante principale (Figure 14) est corrélée à la taille et à l'IMC. Cela est cohérent car l'IMC est calculé en fonction de la taille. De plus, la taille est assez faiblement corrélée aux deux premières composantes principales (0.35 et 0.20, Figure 13). Son influence sur les performances sportives et la corpulence est donc limitée. Cela justifie que l'on ne garde que les 2 premières composantes principales.

En conclusion, le premier axe oppose des profils à forte intensité d'entraînement à des profils à forte masse grasse. Le second axe traduit principalement des différences morphologiques liées au poids et à l'IMC. La troisième composante est surtout associée à la taille et apporte une information seulement complémentaire mais ne permet de tirer aucune conclusion supplémentaire. Le clustering sera donc effectué seulement en 2 dimensions.

5 Classification non supervisée (Clustering)

Afin de regrouper les individus en classes homogènes, nous allons utiliser les résultats de notre ACP. Plutôt que de travailler sur les variables brutes, nous réalisons la classification sur les coordonnées des individus sur les **3 premiers axes factoriels**.

Cette approche permet de baser les groupes sur les dimensions structurantes identifiées précédemment (Intensité, Corpulence, Taille) en éliminant le bruit résiduel des derniers axes.

```
donnees_acp <- res_pca$ind$coord[, 1:3]

# Aperçu des données utilisées pour le clustering
head(donnees_acp)
```

	Dim.1	Dim.2	Dim.3
1	3.178026	-0.20613732	0.5326227
2	-1.128313	0.44504681	2.0336135
3	-1.652054	0.28775885	0.3246140
4	-2.683734	0.01647382	-0.8505631
5	-2.189516	-0.34673298	-1.9837715
6	1.138159	-1.68339118	0.1416179

5.1 Classification Ascendante Hiérarchique (CAH)

Nous effectuons une CAH sur ces coordonnées factorielles en utilisant la distance euclidienne et le critère de Ward (minimisation de l'inertie intra-classe).




Figure 15: Dendrogramme de la classification hiérarchique sur composantes principales

5.1.1 Choix du nombre de classes

Le dendrogramme montre un saut d'inertie majeur lors du passage de 3 à 2 classes. Nous retenons donc une partition en **k=3 classes**. Ce choix est cohérent avec la structure de la variable `level` qui comporte 3 modalités (Débutant, Intermédiaire, Expert). Nous chercherons par la suite à vérifier si ces classes statistiques recouvrent effectivement ces niveaux d'expertise ou si elles révèlent une autre segmentation (ex: distinction Homme/Femme ou Morphologie).

5.2 Méthode des K-means

Nous appliquons maintenant l'algorithme des K-means, toujours sur les coordonnées des 3 premiers axes factoriels.




Figure 16: Partition K-means projetée sur le premier plan factoriel

L'avantage de cette représentation est immédiat : les classes sont, par construction, bien séparées sur les axes factoriels.

5.3 Comparaison des classifications

Comparons la partition obtenue par la CAH et celle des K-means.

Analyse de la stabilité des classes (Matrice de confusion) :


```

classes_cah <- cutree(res_cah, k = 3)

SalleDeSport$cluster_cah <- NA
SalleDeSport$cluster_kmeans <- NA

ids_a_classer <- rownames(donnees_acp)

SalleDeSport[ids_a_classer, "cluster_cah"] <- factor(classes_cah)
SalleDeSport[ids_a_classer, "cluster_kmeans"] <- factor(res_kmeans$cluster)

table_comp <- table(
  CAH = SalleDeSport$cluster_cah,
  Kmeans = SalleDeSport$cluster_kmeans
)

addmargins(table_comp)

```

	Kmeans			
CAH	1	2	3	Sum
1	0	200	0	200
2	39	26	526	591
3	179	3	0	182
Sum	218	229	526	973

En comparant la CAH et les K-means via la table de contingence, nous observons une stabilité remarquable pour deux groupes, mais une hésitation sur le troisième :

- **Le noyau dur (Diagonale forte) :**

- La classe 1 de la CAH correspond parfaitement à la classe 2 des K-means (200 individus, 0 erreur). C’est un groupe très homogène et distinct.
- La classe 3 de la CAH est quasi-identique à la classe 1 des K-means (179 individus sur 182).

- **La zone de flou (Classe centrale) :**

- La classe 2 de la CAH est la plus volumineuse (591 individus) et semble être une classe “fourre-tout”. L’algorithme des K-means, qui réalloue les individus pour optimiser les centres, a “nettoyé” cette classe : il a conservé 526 individus dans son Cluster 3, mais en a réassigné 39 vers le Cluster 1 et 26 vers le Cluster 2.

En conclusion, la méthode des K-means a permis d’affiner la partition en “récupérant” des individus frontières mal classés par la méthode hiérarchique (qui ne peut pas revenir en arrière une fois un regroupement effectué). Nous privilégierons donc la partition K-means pour l’interprétation finale.

5.4 Croisement et Profilage




Figure 17: Analyse croisée des clusters avec les variables qualitatives

En projetant la partition K-means sur le premier plan factoriel et en la croisant avec les variables qualitatives, nous pouvons dresser les portraits-robots des 3 clusters :

- **Cluster 1 (correspondant probablement aux Experts) :** Ce groupe rassemble les individus ayant des séances longues, une forte dépense calorique et un faible taux de masse grasse.
- **Cluster 3 (correspondant probablement à une morphologie spécifique/Surpoids) :** Ce groupe se caractérise par un IMC et un poids élevés, potentiellement corrélés à une pratique moins intense.
- **Cluster 2 (Les “Intermédiaires”) :** Le groupe central et volumineux. Il rassemble la majorité des usagers, avec des performances et une morphologie moyennes. C’est ce manque de caractéristiques extrêmes qui rend ce groupe plus difficile à délimiter (comme vu dans la comparaison CAH/Kmeans).

```
SalleDeSport$cluster <- as.factor(res_kmeans$cluster)

aggregate(cbind(weight, height, duration, calories, fat, bmi) ~ cluster,
          data = SalleDeSport,
          FUN = mean)
```

	cluster	weight	height	duration	calories	fat	bmi
1	1	104.51147	1.787752	1.119771	841.1651	25.10734	33.02060
2	2	72.57991	1.742926	1.702314	1240.6943	16.33843	24.02301
3	3	61.70399	1.686711	1.118935	786.0894	28.68346	21.93867

```
print("Répartition des Niveaux par Cluster :")
```

```
[1] "Répartition des Niveaux par Cluster :"
```

```
table(SalleDeSport$cluster, SalleDeSport$level)
```

	Débutant	Intermédiaire	Expert
1	105	113	0
2	14	24	191
3	257	269	0

```
print("Répartition des Genres par Cluster :")
```

```
[1] "Répartition des Genres par Cluster :"
```

```
table(SalleDeSport$cluster, SalleDeSport$gender)
```

	Homme	Femme
1	218	0
2	139	90
3	154	372

6 Conclusion

En conclusion, cette étude met en évidence que la performance en salle de sport dépend principalement de l'intensité et de la régularité de l'entraînement, mesurées par la durée des séances et la dépense calorique, plutôt que de la morphologie seule. L'analyse descriptive, l'ACP et le clustering montrent plutôt que les profils les plus experts se distinguent par une masse grasse plus faible et des séances plus longues, tandis que le genre et le poids jouent un rôle secondaire. Ces observations montrent que la condition physique est davantage associée à la pratique régulière et soutenue qu'aux caractéristiques morphologiques.