

Projet d'Analyse de Données : Performance en Salle de Sport

Timeo Bossuet, Charles Ganne

Table des matières

1	Introduction : chargement et découverte du jeu de données	1
2	Analyse unidimensionnelle	2
2.1	Variables quantitatives	2
2.2	Variables qualitatives	7
3	Analyse bidimensionnelle	7
3.1	Corrélations entre variables quantitatives (Figure 7)	7
3.2	Variables quantitatives en fonction de variables qualitatives	9
4	Analyse en composantes principales	12
4.1	Analyse du cercle des corrélations	15

1 Introduction : chargement et découverte du jeu de données

Ce projet a pour objectif de mener l'étude descriptive uni- et bi-dimensionnelle d'un jeu de données concernant les clients d'une salle de sport. Voici les 6 premières lignes du jeu de données pour s'en faire une première idée.

	gender	weight	height	duration	calories	fat	water	level	bmi
1	Male	88.3	1.71	1.69	1313	12.6	3.5	3	30.20
2	Female	74.9	1.53	1.30	883	33.9	2.1	2	32.00
3	Female	68.1	1.66	1.11	677	33.4	2.3	2	24.71
4	Male	53.2	1.70	0.59	532	28.8	2.1	1	18.41
5	Male	46.1	1.79	0.64	556	29.2	2.8	1	14.39
6	Female	58.0	1.68	1.59	1116	15.5	2.7	3	20.55

Ce jeu de données comprend des mesures empiriques réalisées sur un échantillon de 973 usagers. Chaque personne est décrite par les variables suivantes :

- *gender* : Sexe du membre de la salle de sport (homme ou femme)

- *weight* : Poids du membre en kilogrammes
- *height* : Taille du membre en mètres
- *duration* : Durée de chaque séance d'entraînement en heures
- *calories* : Total des calories brûlées au cours de chaque séance
- *fat* : Pourcentage de graisse corporelle du membre (appelé "masse grasse")
- *water* : Consommation quotidienne d'eau pendant les séances d'entraînement
- *level* : Niveau d'expérience : débutant (1), intermédiaire (2) et expert (3)
- *bmi* : Indice de masse corporelle (IMC), calculé à partir de la taille et du poids

On observe que la variable *gender* est qualitative nominale et la variable *level* est qualitative ordinaire. De plus, la variable *calories* est quantitative discrète. Les autres variables sont quantitatives continues. Il faut préciser à R les variables qui doivent être considérées comme qualitatives. On utilise donc la fonction `as.factor()` sur les variables *gender* et *level* :

```
SalleDeSport$gender <- factor(SalleDeSport$gender,
                             levels=c("Male","Female"),
                             labels = c("Homme", "Femme"))
SalleDeSport$level <- factor(SalleDeSport$level, levels=c("1","2","3"),
                             labels=c("Débutant","Intermédiaire","Expert"),
                             ordered=TRUE)
```

2 Analyse unidimensionnelle

On commence par étudier chaque variable individuellement.

2.1 Variables quantitatives

Pour chaque variable quantitative, on examine des statistiques descriptives (moyenne, médiane, quartiles, etc.). On trace chaque boxplot, et certains histogramme.




Figure 1: Boxplots : poids, masse grasse, IMC et calories

2.1.1 Poids (weight)

Le boxplot (Figure 1) montre une médiane de 70 kg, avec une dispersion notable (la moitié des individus se situe entre 58 et 86 kg). On observe des valeurs atypiques élevées (points au-dessus de 125–130 kg). L’histogramme a confirmé une distribution asymétrique à droite : beaucoup d’individus entre 50 et 85 kg avec un maximum de fréquence autour de 60–70 kg. On a observé une queue à droite marquée, correspondant à des individus plus lourds (au-delà de 100 kg), déjà visibles comme valeurs atypiques/outliers sur le boxplot. La distribution n’est donc pas strictement gaussienne.

2.1.2 Masse grasse (fat)

La médiane est autour de 26%, avec la majorité des valeurs entre 21% et 29%. L’étendue va approximativement de 10% à 35%. Le boxplot (Figure 1) ne montre pas de points atypiques extrêmes ; l’ensemble semble relativement homogène, avec une dispersion modérée. L’histogramme (Figure 2) semble légèrement multimodal, ce qui peut refléter des différences physiologiques (genres ou niveaux).

2.1.3 IMC (bmi)

On observe une médiane de 24, avec la moitié des individus entre 20 et 28. En revanche, on observe de nombreux outliers élevés (au-delà de 40 et jusqu’à 50). Cette queue droite importante sur l’histogramme (Figure 2) confirme la présence d’individus en surpoids ou obésité, déjà visible sur le boxplot via de nombreux outliers. Cela rejoint nos observations sur le poids où on avait remarqué déjà la présence d’outlier avec des individus bien au delà de 100kg.




Figure 2: Histogrammes : masse grasse et IMC

2.1.4 Calories (calories)

Le boxplot (Figure 1) indique une médiane proche de 900 kcal, avec un intervalle interquartile d'environ 750 à 1100 kcal. On voit plusieurs valeurs atypiques élevées (au-delà de 1600/1750 kcal), ce qui indique des séances exceptionnellement énergivores. Cette structure est cohérente avec une distribution asymétrique à droite : des séances “standard”, et quelques séances très intenses (Figure 3). Les 30 bins sont adaptés ici, ils révèlent la forme globale, tout en conservant la visibilité de la queue à droite. Un nombre plus faible masquerait les extrêmes.




Figure 3: Histogrammes : calories et consommation d'eau




Figure 4: Boxplots : eau, durée et taille

2.1.5 Eau (water)

Figure 4, la médiane est autour de 2,6 L, et l'intervalle interquartile va de 2,2 à 3,1 L. L'étendue est d'environ 1,5 à 3,7 L. La distribution paraît assez concentrée autour de 2–3 L, sans valeurs extrêmes marquantes. Figure 3, on remarque des pics marqués autour de certaines valeurs (notamment 2,7

L et 3,5 L), suggérant des valeurs arrondies ou/et des comportements standardisés (bouteilles, recommandation de cette salle de sport).

2.1.6 Durée (duration)

Figure 4, la médiane est autour de 1,25 h, et la moitié des séances se situe approximativement entre 1,05 et 1,45h. Les durées extrêmes vont d'environ 0,5 h à 2 h. L'histogramme (Figure 5) montre une concentration nette entre 1 h et 1,5 h, avec quelques séances plus courtes et plus longues. Ça pourrait par exemple être une recommandation de la salle de sport de faire une séance courte, deux séances moyennes et une séance longue par semaine. Les 30 bins permettent de bien visualiser le pic entre 1h et 1,5 h sans trop lisser.

2.1.7 Taille (height)

Figure 4, la médiane est proche de 1,70–1,72 m, avec un intervalle interquartile entre 1,62 et 1,80 m. Le boxplot ne met pas en évidence d'outliers. L'histogramme (Figure 5) suggère une distribution plutôt concentrée entre 1,60 et 1,80 m, avec deux petites “bosses” (distribution pas parfaitement en cloche, probablement liée au fait que hommes et femmes soient dans le même jeu de données), mais sans valeurs extrêmes dominantes. En traçant les graphiques avec différents nombres de bins, on a remarqué que certaines configurations masquaient le double pic tandis que d'autres le faisait clairement apparaître. On a donc choisi 19 bins pour qu'ils apparaissent sans trop montrer les petites variations autour.




Figure 5: Histogrammes : durée des séances et taille des adhérents

2.2 Variables qualitatives

Étudions à présent les distributions des variables qualitatives `gender` et `level`. On visualise ces répartitions avec des diagrammes en barres.




Figure 6: Répartition des adhérents par genre et par niveau

2.2.1 Le genre

Le diagramme en barres (Figure 6) montre une répartition relativement équilibrée entre hommes et femmes, avec une légère majorité d'hommes dans l'échantillon. Cette distribution suggère une population globalement mixte, ce qui limite le risque de biais lié à une surreprésentation marquée d'un genre.

2.2.2 Le niveau

La répartition par niveau d'expérience met en évidence une majorité d'individus de niveau intermédiaire et de débutants. Les experts constituent le groupe le moins représenté. Cette structure est cohérente avec un contexte de pratique sportive, où les niveaux intermédiaires sont généralement les plus fréquents, tandis que les niveaux experts restent plus rares.

3 Analyse bidimensionnelle

3.1 Corrélations entre variables quantitatives (Figure 7)

On explore à présent les relations entre les variables quantitatives avec des matrices de corrélations.




Figure 7: Matrices de corrélations, séparées par genres

Sur la matrice mixte, on a observé une corrélation positive entre le poids et la taille, les individus plus grands auraient tendance à être plus lourds. L'IMC, défini à partir du poids et de la taille, est logiquement très fortement corrélé au poids. En revanche, sa corrélation avec la taille apparaît faible et légèrement négative dans l'échantillon global. Lorsque l'analyse est menée séparément chez les hommes et les femmes, cette corrélation négative devient plus marquée, ce qui est plus cohérent avec la formule de calcul de l'IMC et suggère que l'effet de la taille est en partie masqué dans l'analyse globale. De plus, la corrélation entre poids et taille disparaît complètement lorsqu'on sépare hommes et femmes.

La relation entre la durée des séances et les calories brûlées est particulièrement forte, ce qui confirme que la dépense énergétique dépend avant tout du temps consacré à l'effort. La consommation d'eau est également positivement liée à la durée et aux calories, bien que de manière plus modérée. Ces relations restent globalement stables lorsque l'on distingue les hommes et les femmes, ce qui indique des mécanismes communs indépendants du genre.

La masse grasse se distingue par des corrélations négatives avec la durée des séances, les calories brûlées et la consommation d'eau. Cela suggère que les individus présentant un pourcentage de masse grasse plus élevé ont tendance à réaliser des séances plus courtes et moins intenses, accompagnées d'une hydratation plus faible. À l'inverse, les variables morphologiques telles que le poids et la taille ne sont pas liées aux indicateurs de performance sportive considérés ici. Cette dissociation indique que, dans ce jeu de données et avec ces variables, la morphologie seule n'explique pas directement les performances, qui semblent davantage dépendre de l'effort fourni et de la composition corporelle.

Enfin, il est étonnant de voir que le masse grasse n'est pas corrélé au poids ou à l'IMC. Cette variable n'augmente donc pas mécaniquement avec le poids, surtout dans une population sportive où la masse musculaire peut représenter une part importante du poids total. Cette observation avait déjà été faite lors de l'expérience super-size me. Le sujet n'avait pas prit beaucoup de poids

mais était quand même devenu en très mauvaise santé, notamment à cause de sa masse grasse (et beaucoup d'autres troubles liés à la junk-food).

3.2 Variables quantitatives en fonction de variables qualitatives

Comparons les distributions des variables quantitatives selon le genre et le niveau à l'aide de box-plots.




Figure 8: Boxplots des variables quantitatives selon le genre




Figure 9: Boxplots des variables quantitatives selon le niveau

	Variable	Eta2_Gender	Eta2_Level
calories	calories	0.0226943595	0.5093431711
water	water	0.4457674667	0.1685026462
duration	duration	0.0001488394	0.6217788488
weight	weight	0.3356351005	0.0004401156
bmi	bmi	0.0973253285	0.0019553712
height	height	0.3404763329	0.0008769585
fat	fat	0.1659009315	0.6480331227




Figure 10: Calcul du rapport de corrélation η^2

Pour chaque variable quantitative, on calcule le rapport de corrélation η^2 vis-à-vis de chaque variable qualitative (genre et niveau) à l'aide de la fonction `eta2()`. Le tableau obtenu donne, pour chaque variable quantitative, la part de variance expliquée par le genre ou par le niveau. Une grande valeur de η^2 pour fat vs gender indique que le pourcentage de masse grasse diffère significativement entre hommes et femmes. Une valeur élevée de η^2 pour duration vs level suggérerait que la durée moyenne de séance varie selon l'expérience. Des valeurs proches de 0 (pour water vs gender, par exemple) signifient une absence de lien fort.

Entre les hommes et les femmes, on observe une différence de poids notable. Celle-ci va de paire avec la taille. Bien que nous n'ayons pas relevé de corrélation entre ces deux variables en séparant par sexe, le coefficient était tout de même de 0.37 sur la matrice mixte. Ces trois variables sont donc liées mais il n'y a pas d'observation particulière à faire à ce niveau là. La durée des séances et le nombre de calories dépensées ne semblent pas liées au sexe. Nous avons vu que ces deux variables étaient fortement corrélées entre elles sur la matrice mixte, d'où les observations similaires lorsqu'on les observe indépendamment. On relève toutefois la présence d'outliers chez les deux genres pour la variable calories et non pour la durée. Selon les corrélations établies précédemment, on s'attend à ce que ces mêmes individus aient des séances plus longues et une masse grasse plus basse. Et en effet, sur les boxplot de la masse grasse, nous retrouvons ces outliers. Une autre observation plus notable est que les femmes ont une masse grasse nettement plus élevée. Il peut y avoir plusieurs explications à cela, et le jeu de données n'inclue pas certaines variables potentiellement clé à ce sujet telles que la maternité ou l'âge. Toutefois, une recherche sur google scholar tend à confirmer cette observation. Le graphique suivant, allant de paire avec la corrélation inverse entre la consommation d'eau et la masse grasse établie précédemment, montre que les femmes semblent consommer moins d'eau. On avait toutefois déjà observé que les personnes avec une masse grasse plus élevée consommaient moins d'eau. De plus, cette corrélation restait vraie quand on séparait les matrices par sexe, c'est donc le lien eau-fat plutôt que eau-genre que l'on gardera. Enfin, l'IMC par genre. On remarque la présence de certaines personnes en situation d'obésité sévère et morbide seulement chez les hommes, tandis qu'il n'y a pas de femmes avec un IMC supérieur à 35. La tendance au sur-poids est globalement

plus prononcée chez les hommes que chez les femmes. Cette tendance est inverse à celle observée sur le masse grasse.

Sur le premier graphique, le poids ne semble pas lié au niveau, car les 3 niveaux ont leur intervalle inter-quartile entre 57 et 87. Toutefois, il est notable que les experts ont un poids clairement borné entre 55 et 90, ce qui n'est pas le cas des débutants et des intermédiaires. Ainsi, une tendance se dessine tout de même quand au poids qu'aurait un expert. La taille également semble non liée au niveau. On remarque toutefois que l'intervalle semble s'élargir quand le niveau augmente. Mais on avait observé sur le premier violin plot de la taille un double pic dans la distribution. Cela pourrait donc être un biais résiduel dû au genre. On remarque une tendance claire et prononcée au niveau de la durée des séances. Les experts ont tous des séances longues, tandis que les intermédiaires font des séances moins longues et les débutant encore moins. Étant donné la corrélation forte entre la durée des séances et les calories dépensées, on retrouve cette même tendance sur le graphique suivant, le niveau allant croissant avec les calories dépensées. Cette tendance semble moins prononcée pour la consommation d'eau. Elle l'est malgré tout, on la visualise simplement un peu moins parce que tout le monde consomme globalement des quantités d'eau comparables. Toutefois, on remarque encore que les experts (on le sait déjà, faisant des séances plus longues et plus énergivores) consomment plus d'eau que les débutants et intermédiaires. Cette tendance est toutefois liée aux deux précédentes, il n'y a pas de lien de causalité notable entre la consommation d'eau et l'expertise dans un sport. Le masse grasse quand à lui fortement corrélé à l'expertise. Il semble même se dessiner une condition nécessaire et suffisante car pas un seul adhérent avec un masse grasse entre 12 et 18 n'est débutant ou intermédiaire, et tous les gens ayant un masse grasse dans cet intervalle sont classés experts. À l'inverse, les gens ayant une masse grasse plus élevée (de 20 à 35%) seront forcément débutant ou intermédiaire. Cette observation est tout à fait cohérente avec ce qui se trouve dans la littérature (Sedukin D. V. et al., 2025), (Duncan M. J. et al., 2016). On observe également la non présence d'outliers, contrairement au graphique sur l'IMC. En effet, sur ce dernier on retrouve les outliers en situation d'obésité grave que nous avons identifié précédemment. Tandis que les experts ne sont que rarement en situation d'obésité. En effet, un IMC de 35 est déjà considéré comme extrême pour un expert. La boîte est également beaucoup plus fine, plaçant l'IMC d'un expert entre la fine fourchette de 23 à 27 avec une tolérance beaucoup plus réduite que pour les débutants et intermédiaires. Pour ces derniers, l'écart inter quartile est entre 20 et 30 avec une moustache s'étendant de 10 à 43, ce qui inclut les situations de maigreur et plusieurs nuances d'obésité et de sur-poids.

En conclusion, l'expertise se distingue par une masse grasse réduite (12-18 %). Bien que le genre influence la répartition des masses grasses et les extrêmes de l'IMC, la performance reste dictée par la durée des séances et l'intensité de la dépense calorique. Ces résultats valident la littérature scientifique en confirmant que l'assiduité à l'entraînement est le principal levier pour optimiser sa santé physique.

4 Analyse en composantes principales


Le principe de l'ACP repose sur la création de composantes principales par combinaison linéaire des variables originales. En éliminant la redondance d'information (corrélations), cette méthode permet de visualiser les individus sur des plans factoriels et d'identifier les axes qui expliquent la plus grande part de l'inertie du nuage de points.

Le jeu de données oppose ici la **morphologie** (poids, taille, IMC, graisse) à la **pratique sportive** (durée, calories, eau, niveau).

L'analyse préalable montre de fortes corrélations, notamment entre la durée et les calories, ou le poids et l'IMC. En raison de l'hétérogénéité des unités (kg, h, kcal), nous avons vu qu'elles n'étaient pas à la même échelle. Nous appliquons donc une **ACP centrée réduite**. Cette normalisation assure une contribution équitable de chaque variable à l'inertie, empêchant les variables à forte variance (comme les calories) de dominer l'analyse.


```
# ACP centrée-réduite
res_pca <- PCA(
  SalleDeSport,
  scale.unit = TRUE,
  quali.sup = c(which(names(SalleDeSport)=="gender"),
                 which(names(SalleDeSport)=="level")),
  graph = FALSE
)

# Valeurs propres (choix du nombre d'axes)
#res_pca$eig
fviz_eig(res_pca, addlabels = TRUE)
```




Les deux premiers axes factoriels expliquent 68,3% de l'inertie totale (41,5% pour l'axe 1 et 26,8% pour l'axe 2), assurant une représentation fidèle des données. Bien que l'essentiel de l'analyse repose sur ce premier plan factoriel, la contribution du troisième axe (17,6%) reste significative et ne sera pas totalement occultée lors de l'interprétation.

```
# cercle des corrélations
fviz_pca_var(res_pca,
             repel = TRUE)
```



```
# matrice des corrélations
cor_3axes <- res_pca$var$cor[, 1:3, drop = FALSE]

corrplot(
  cor_3axes,
  method = "ellipse",
  addCoef.col = "black",
  number.cex = 0.8,
  tl.cex = 0.9
)
```



4.1 Analyse du cercle des corrélations

Dans un premier temps, on remarque que les flèches des variables poids, durée, calories, eau, IMC sont plus longues. Ces variables sont donc bien représentées sur le plan factoriel. La flèche de la hauteur est plus proche du centre, cette variable est donc moins bien représentée par les deux premières composantes principales.


L'axe des abscisses (Dim1, 41.5 %) est corrélé plus fortement à calories (0.80), durée (0.73), eau (0.73) et masse grasse (-0.83). Ainsi, cette composante principale rassemble les variables durée, calories et eau, qui traduisent de l'intensité d'un entraînement, et les oppose à la variable masse grasse. C'est une observation que nous avons faite précédemment, les personnes avec une masse grasse plus élevée font des séances moins intenses.

L'axe des ordonnées est principalement corrélé à l'IMC et au poids, les deux flèches sont très proches. Il est également négativement corrélé à la durée et aux calories. Cela nous permet d'opposer la corpulence des individus et leur endurance.

Enfin, la troisième composante principale est corrélée à la taille et à l'IMC. Cela est cohérent car l'IMC est calculé en fonction de la taille. De plus la taille est assez faiblement corrélée aux deux premières composantes principales (0.35 et 0.20). Son influence sur les performances sportives et la corpulence est donc limitée. Cela justifie que l'on ne garde que les 2 premières composantes principales.

En conclusion, le premier axe oppose des profils à forte intensité d'entraînement à des profils à forte masse grasse. Le second axe traduit principalement des différences morphologiques liées au poids et à l'IMC. La troisième composante est surtout associée à la taille et apporte une information complémentaire.

```
# Graphique des individus
fviz_pca_ind(res_pca,
  geom = "point",
  habillage = "gender",
  addEllipses = TRUE)
```



```
# Autre lecture intéressante :
fviz_pca_ind(res_pca, col.ind = "cos2")
```

Individuals – PCA

